

# AUSGLEICH VON MESSWERTEN

Torsten Hehl

Physikalisches Institut Tübingen


18.12.2023

Anpassung von Messwerten  $y_i$  an  
Modellfunktion  $y$ :

$$y(x) = y(x; a_1 \dots a_M)$$

## METHODE DER KLEINSTEN QUADRATE (C.F. GAUSS)

$$\sum_{i=1}^N [y_i - y(x_i; a_1 \dots a_M)]^2 \rightarrow \text{Min.}$$



**Annahme:** Messwerte  $y_i$  seien jeweils normalverteilt:

$$P_i = \frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{(y_i - y)^2}{2\sigma_i^2}}$$


max. Wahrscheinlichkeit für 1 Punkt:  $y = y_i$

Viele Punkte → kombinierte Wahrscheinlichkeit

## MAXIMUM LIKELIHOOD FÜR NORMALVERTEILUNGEN

$$P = \prod_{i=1}^N P_i \sim \prod_{i=1}^N e^{-\frac{1}{2} \left( \frac{y_i - y(x_i)}{\sigma_i} \right)^2} \rightarrow \text{Max.}$$

$$-\ln P \sim \chi^2 = \sum_{i=1}^N \left( \frac{y_i - y(x_i)}{\sigma_i} \right)^2 \rightarrow \text{Min.}$$



## $\chi^2$ -VERTEILUNGSFUNKTION (HELMERT 1875, PEARSON 1900)

$$F(\chi^2) = \frac{1}{\Gamma(\lambda)2^\lambda} \int_0^{\chi^2} u^{\lambda-1} e^{-\frac{1}{2}u} du \quad .$$

$$\lambda = \frac{N - M}{2} \quad , \quad E(\chi^2) = (N - M) \quad , \quad \sigma^2(\chi^2) = 2(N - M)$$

→  $\frac{\chi^2}{N - M}$ : Maß für Güte der Anpassung (reduziertes  $\chi^2$ )

≈ 1: Gute Anpassung

≫ 1: Inkonsistenz zwischen Daten und Modellfunktion, meist Fehler zu klein angegeben

≪ 1: Anpassung ist konsistent, aber Fehler zu groß oder Daten geschönt

## BSP.: MESSUNG DER LICHTGESCHWINDIGKEIT (1948)

Bergstrand (1948)	299 793(2) km/s
Essen et al. (1947)	299 792.0(45) km/s
Jones (1947)	299 782(25) km/s

$$\chi^2 = \sum_{i=1}^3 \left( \frac{c_i - \bar{c}}{\Delta c_i} \right)^2 \rightarrow \text{Min.}$$

$$\frac{d\chi^2}{d\bar{c}} = 0 = \sum_{i=1}^3 2 \frac{c_i - \bar{c}}{\Delta c_i^2} = 0$$

$$\longrightarrow \bar{c} = \frac{\sum_{i=1}^3 \frac{c_i}{\Delta c_i^2}}{\sum_{i=1}^3 \frac{1}{\Delta c_i^2}}$$

## Lineare Modellfunktion


$$y(x) = y(x; a, b) = a + bx$$

$$\chi^2(a, b) = \sum_{i=1}^N \left( \frac{y_i - a - bx_i}{\sigma_i} \right)^2 \rightarrow \text{Min.}$$

Daraus folgen die Bedingungen

$$0 = \frac{\partial \chi^2}{\partial a} = -2 \sum_{i=1}^N \frac{y_i - a - bx_i}{\sigma_i^2}$$

$$0 = \frac{\partial \chi^2}{\partial b} = -2 \sum_{i=1}^N \frac{x_i(y_i - a - bx_i)}{\sigma_i^2}$$



Mit den Abkürzungen

$$S \equiv \sum_{i=1}^N \frac{1}{\sigma_i^2}, \quad S_x \equiv \sum_{i=1}^N \frac{x_i}{\sigma_i^2}, \quad S_y \equiv \sum_{i=1}^N \frac{y_i}{\sigma_i^2}$$
$$S_{xx} \equiv \sum_{i=1}^N \frac{x_i^2}{\sigma_i^2}, \quad S_{xy} \equiv \sum_{i=1}^N \frac{x_i y_i}{\sigma_i^2}$$

erhalten wir das Gleichungssystem:

$$\begin{aligned} aS + bS_x &= S_y \\ aS_x + bS_{xx} &= S_{xy} \end{aligned}$$

**Lösungen:** (mit der Determinante  $D = SS_{xx} - S_x^2$ ):

$$\begin{aligned} a &= \frac{S_{xx}S_y - S_x S_{xy}}{D} \\ b &= \frac{SS_{xy} - S_x S_y}{D} \end{aligned}$$

$$\sigma_f^2 = \sum_{i=1}^N \sigma_i^2 \left( \frac{\partial f}{\partial y_i} \right)^2$$

Hier:

$$\begin{aligned} \frac{\partial a}{\partial y_i} &= \frac{S_{xx} - S_x x_i}{\sigma_i^2 D} \\ \frac{\partial b}{\partial y_i} &= \frac{S x_i - S_x}{\sigma_i^2 D} \end{aligned}$$

Damit erhält man:

$$\begin{aligned} \sigma_a^2 &= \frac{S_{xx}}{D} \\ \sigma_b^2 &= \frac{S}{D} \end{aligned}$$



Modellfunktion als Summe von beliebigen  $f(x)$  mit linearen Koeffizienten:

$$y(x; a_1, \dots, a_M) = \sum_{j=1}^M a_j f_j(x)$$

Dann ergibt sich lineares Gleichungssystem  $M$ -ter Ordnung:

$$\frac{\partial}{\partial a_j} \sum_{i=1}^N \frac{\left( y_i - \sum_{j=1}^M a_j f_j(x_i) \right)^2}{\sigma_i^2} = 0$$

Beispiele:

Polynom  $M - 1$ -ten Grades:  $y = a_1 + a_2 x + a_3 x^2 + \dots + a_M x^{M-1}$

Legendrepolynome:  $P_{j-1}(x) \equiv f_j(x)$  mit Rekursion:

$$P_0(x) = 1, \quad P_1(x) = x$$

$$(n+1)P_{n+1}(x) = (2n+1)xP_n(x) - nP_{n-1}(x)$$

Transformation von  $y$  so, dass lineare Funktion  $y'$  entsteht:

Beispiel:

$$y(x; a, b) = e^{a+bx_i}$$

Transformation (Logarithmus):

$$y' = \ln y = a + bx_i$$

Wichtig: Transformation der Fehler  $\sigma_i$  nicht vergessen!

$$(\sigma'_i)^2 = \sigma_i^2 \frac{dy'_i}{dy_i} = \sigma_i^2 \frac{d}{dy_i} \ln y_i = \frac{\sigma_i^2}{y_i}$$

Zu minimieren ist dann:

$$\chi^2(a, b) = \sum_{i=1}^N \frac{y_i (\ln y_i - a - bx_i)^2}{\sigma_i^2} \rightarrow \text{Min.}$$

Suche des Minimums von  $\chi^2$  im  $M$ -dimensionalen Raum der Parameter  $a_j$

- $M$  Minimalbedingungen führen zu nichtlinearem GS
- sinnvoller Startvektor  $a_o$  nahe Minimum

Näherung durch quadratische Form


Eindimensionaler Fall:

$$\frac{d\chi^2}{da} = b \quad \frac{d^2\chi^2}{da^2} = A$$

→ verbesserter Parameter

$$a' = a_o + \frac{b}{A}$$

Minimum der Parabel



## QUADRATISCHE NÄHERUNG

$$\chi^2(a) = c + b \cdot a + \frac{1}{2} a^T A a$$

Gradient  $b_k$

$$b = \text{grad } \chi^2(a_0), \quad b_i = \left. \frac{\partial \chi^2}{\partial a_i} \right|_{a=a_0}$$

Hesse-Matrix  $A_{ik}$ :

$$A_{ik} = \left. \frac{\partial^2 \chi^2}{\partial a_i \partial a_k} \right|_{a=a_0}$$

$$\rightarrow a' = a + bA^{-1}$$

## PROBLEME:

- ineffizienter Zick-Zack-Kurs bei Verfolgung des steilsten Abfalls
- Problem mit  $A^{-1}$ , wenn  $A$  nicht positiv definit

## LÖSUNG:

- konjugierte Richtungen  $u$  und  $v$  nötig mit  $uAv = 0$
- Näherung der invertierten Hessematrix in variabler Metrik  $\rightarrow$  Quasi-Newton-Verfahren

Nelder u. Mead 1965


## SIMPLEX

$M + 1$  Punkte  $a_i$  im  $M$ -dimensionalen Raum der anzupassenden Parameter (2-dim.: Dreieck)

Schrittweise Näherung an Minimum durch:

- Spiegelung von schlechtestem Punkt
- Streckung, wenn gespiegelter Punkt der beste ist
- Kontraktion, wenn gespiegelter Punkt größer als zweitgrößter ist

Verfahren ist robust, aber langsam



## ■ Unbeschränkte Parameter

- **Newton-CG** (Nonlinear conjugate gradient method)
- **BFGS** (Broyden–Fletcher–Goldfarb–Shanno, modifiziertes Quasi-Newton-Verfahren)
- **dogleg** (dog-leg trust-region algorithm)
- **trust-ncg, trust-krylov, trust-exact**

## ■ Beschränkte/gebundene Parameter

- **Powell-Methode** (modifiziertes CG-Verfahren)
- **L-BFGS-B** (Variante von BFGS)
- **TNC** (Truncated Newton method, ohne Hesse-Matrix)
- **COBYLA** (Constrained Optimization BY Linear Approximation)
- **SLSQP** (Sequential Least Squares Programming, mod. BFGS)
- **trust-constr**

Umsetzung in Python: `scipy.optimize`